nba_salary

March 25, 2020

0.1 Introdução a Aprendizado de Máquina

- 0.1.1 Professor Enerson Oliveira
- 0.1.2 João Manoel Lins 1924520-X
- 0.1.3 joaomanoellins@gmail.com

O objetivo é encontrar um modelo, que de acordo com as médias do desempenho dos jogadores em quadra, idade, altura, peso e entre outros, consiga prever seu salário.

Em memória de Kobe Bryant

#KB24

```
import os
import numpy as np
import pandas as pd

import seaborn as sns
import matplotlib.pyplot as plt

pd.options.display.max_columns = None
sns.set()

%matplotlib inline
```

```
[2]: dataset_path = os.path.join('.', 'datasets', 'NBA_Players.csv')
```

1 Carregando o dataset

```
[3]: nba = pd.read_csv(dataset_path)
```

2 Analisando os dados

```
[4]: nba.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 550 entries, 0 to 549
Data columns (total 30 columns):
TEAM
                    550 non-null object
                    550 non-null object
NAME
EXPERIENCE
                    550 non-null int64
URL
                    550 non-null object
POSITION
                    550 non-null object
                    550 non-null object
 AGE
                    550 non-null float64
HT
 WT
                    550 non-null float64
 COLLEGE
                    550 non-null object
 SALARY
                    550 non-null object
 PPG_LAST_SEASON
                    538 non-null float64
 APG_LAST_SEASON
                    538 non-null float64
 RPG_LAST_SEASON
                    538 non-null float64
 PER_LAST_SEASON
                    538 non-null float64
 PPG_CAREER
                    550 non-null float64
 APG_CAREER
                    550 non-null float64
 RGP CAREER
                    550 non-null float64
 GP
                    550 non-null int64
                    550 non-null float64
 MPG
FGM_FGA
                    550 non-null object
 FGP
                    550 non-null float64
 THM_THA
                    550 non-null object
 THP
                    550 non-null float64
 FTM_FTA
                    550 non-null object
 FTP
                    550 non-null float64
 APG
                    550 non-null float64
 BLKPG
                    550 non-null float64
STLPG
                    550 non-null float64
                    550 non-null float64
 TOPG
 PPG
                    550 non-null float64
dtypes: float64(18), int64(2), object(10)
memory usage: 129.0+ KB
```

Legenda:

PPG_LAST_SEASON - Points Per Game - Last Season

APG LAST SEASON - Assists Per Game - Last Season

RPG LAST SEASON - Rebounds Per Game - Last Season

PER_LAST_SEASON - Player Efficiency Rating is the overall rating of a player's per-minute statistical production. The league average is 15.00 every season.

PPG CARRER - Points Per Game - Carrer

APG CARRER - Assists Per Game - Carrer

RPG_CARRER - Rebounds Per Game - Carrer

GP - Games Played

MPG - Minutes Per Game

 FGM_FGA - Field Goals Made-Attempted Per Game

FGP - Field Goal Percentage

THM_THA - ???

THP - ???

 ${\tt FTM_FTA}$ - Free Throws Made-Attempted Per Game

FTP - Free Throws Percentage

APG - Assists Per Game

BLKPG - Blocks Per Game

STLPG - Steals Per Game

TOPG - Turnover Per Game

PPG - Points Per Game

[5]: nba.describe()

CE3.		EVDEDTENGE	IIT	ī 700	DDG I AGT GEAGON	`	
[5]:		EXPERIENCE	HT	WT	PPG_LAST_SEASON	\	
	count	550.000000	550.000000	550.000000	538.000000		
	mean	4.018182	200.512218	98.371255	7.316171		
	std	4.144876	8.592139	10.883866	6.625138		
	min	0.000000	175.260000	76.920000	0.000000		
	25%	1.000000	193.675000	90.500000	1.000000		
	50%	3.000000	200.660000	97.290000	6.150000		
	75%	6.000000	208.280000	106.330000	11.700000		
	max	20.000000	220.980000	131.220000	30.400000		
		APG_LAST_SE	ASON RPG_I	AST_SEASON	PER_LAST_SEASON	PPG_CAREER	\
	count	538.00	0000	538.000000	538.000000	550.000000	
	mean	2.66	7472	1.727881	10.870725	6.944545	
	std	2.80	9521	1.861049	9.382982	5.912676	
	min	0.00	0000	0.000000	-28.480000	0.000000	
	25%		200000	0.000000	3.745000	1.500000	
	50%	1.90	0000	1.100000	12.105000	6.400000	
			0000	2.875000	15.877500	10.500000	
	max	16.00		12.300000	133.950000	27.200000	
		APG_CAREER	RGP_CAREEF	R G	P MPG	FGP \	
	count	550.000000	550.000000	550.00000	0 550.000000 550	0.00000	
	mean	2.622182	1.708182	249.561818	8 16.548000 (0.350011	
	std	2.665679	1.732489			0.202934	
	min	0.000000	0.000000			0.00000	
	25%	0.300000	0.125000			0.327750	

```
50%
           1.800000
                         1.200000
                                    141.500000
                                                  18.250000
                                                                0.430500
75%
           4.100000
                         2.800000
                                    409.500000
                                                  26.100000
                                                                0.469000
max
          13.400000
                        11.700000
                                   1471.000000
                                                  38.800000
                                                                1.000000
               THP
                            FTP
                                         APG
                                                   BLKPG
                                                                STLPG
                                                                              TOPG
                                                                        550.000000
       550.000000
                    550.000000
                                 550.000000
                                              550.000000
                                                           550.000000
count
                                                                          0.943273
mean
         0.230956
                      0.560867
                                   1.493455
                                                0.336909
                                                             0.541091
std
         0.171717
                      0.331210
                                   1.658239
                                                0.409453
                                                             0.454148
                                                                          0.823085
min
         0.000000
                      0.000000
                                   0.000000
                                                0.000000
                                                             0.000000
                                                                          0.000000
25%
         0.000000
                                   0.125000
                                                0.000000
                                                                          0.200000
                      0.423000
                                                             0.100000
50%
         0.310000
                      0.723000
                                   1.100000
                                                0.200000
                                                             0.500000
                                                                          0.900000
75%
         0.358750
                      0.796500
                                   2.100000
                                                0.500000
                                                             0.800000
                                                                          1.400000
max
          1.000000
                      1.000000
                                   9.800000
                                                2.400000
                                                             2.300000
                                                                          4.000000
               PPG
count
       550.000000
mean
         6.944545
std
         5.912676
min
         0.000000
25%
         1.500000
50%
         6.400000
75%
         10.500000
max
        27.200000
nba.head(5)
              TEAM
                             NAME
                                    EXPERIENCE
   Boston Celtics
                     Aron Baynes
                                              6
                                              0
   Boston Celtics
                    Justin Bibbs
1
                                              1
2 Boston Celtics
                     Jabari Bird
3 Boston Celtics
                    Jaylen Brown
                                              2
   Boston Celtics
                       PJ Dozier
                                              1
                                                   POSITION
                                                                        HT
                                              URL
                                                              AGE
                                                                                WT
   http://www.espn.com/nba/player/_/id/2968439
                                                          SF
                                                               31
                                                                    208.28
                                                                            117.65
1
   http://www.espn.com/nba/player/_/id/3147500
                                                           G
                                                                    195.58
                                                                             99.55
2 http://www.espn.com/nba/player/_/id/3064308
                                                          SG
                                                                    198.12
                                                                             89.59
   http://www.espn.com/nba/player/_/id/3917376
3
                                                           F
                                                               21
                                                                    200.66
                                                                             99.55
   http://www.espn.com/nba/player/_/id/3923250
                                                          PG
                                                                    198.12
                                                                             92.76
                                                               21
             COLLEGE
                           SALARY
                                    PPG_LAST_SEASON
                                                        APG_LAST_SEASON
   Washington State
                       5,193,600
                                                 6.0
                                                                     1.1
0
                                                 0.0
                                                                     0.0
1
      Virginia Tech
                      Not signed
2
         California
                       1,349,464
                                                 3.0
                                                                     0.6
3
                                                14.5
                                                                     1.6
         California
                       5,169,960
4
     South Carolina Not signed
                                                 1.0
                                                                     0.0
```

[6]:

[6]:

```
APG_CAREER
                                                                  RGP_CAREER \
   RPG_LAST_SEASON
                     PER_LAST_SEASON
                                       PPG_CAREER
0
                5.4
                                               5.4
                                                            0.7
                                                                         4.4
                                12.09
                0.0
                                0.00
                                               0.0
                                                            0.0
                                                                         0.0
1
2
                1.5
                                12.18
                                               3.0
                                                            0.6
                                                                         1.5
3
                4.9
                                13.69
                                              10.4
                                                            1.2
                                                                         3.8
                0.5
                                -4.82
                                               1.0
                                                            0.0
                                                                         0.5
   GP
        MPG FGM_FGA
                        FGP
                             THM_THA
                                         THP
                                             FTM_FTA
                                                               APG
                                                                     BLKPG \
                                                         FTP
  376
                                                               0.7
       15.0 2.2-4.3 0.502 0.0-0.1 0.143 1.0-1.3 0.802
                                                                       0.5
0
1
    0
        0.0
                   0
                      0.000
                                    0.000
                                                    0
                                                       0.000
                                                               0.0
                                                                       0.0
2
        8.8 1.2-2.0 0.577
   13
                             0.2-0.5 0.429 0.5-1.0
                                                       0.462
                                                               0.6
                                                                       0.1
3
  148 23.6 3.8-8.3 0.461
                             1.1-3.0 0.379 1.6-2.4
                                                      0.658
                                                               1.2
                                                                       0.3
        1.5 0.5-1.0 0.500 0.0-0.0 0.000 0.0-0.0 0.000
                                                               0.0
                                                                       0.0
   STLPG
           TOPG
                  PPG
     0.2
            0.8
                  5.4
0
1
     0.0
            0.0
                  0.0
2
     0.2
            0.6
                  3.0
            1.3
3
     0.7
                 10.4
     0.0
            0.5
4
                  1.0
```

[7]: [col for col in nba.columns.array]

```
[7]: ['TEAM',
      ' NAME',
      ' EXPERIENCE',
      'URL',
      ' POSITION',
      ' AGE',
      ' HT',
      'WT',
      ' COLLEGE',
      ' SALARY',
      ' PPG_LAST_SEASON',
      ' APG LAST SEASON',
      ' RPG_LAST_SEASON',
      ' PER_LAST_SEASON',
      ' PPG_CAREER',
      ' APG_CAREER',
      ' RGP_CAREER',
      ' GP',
      ' MPG',
      ' FGM_FGA',
      ' FGP',
      ' THM_THA',
      'THP',
      ' FTM_FTA',
```

```
' FTP',
' APG',
' BLKPG',
' STLPG',
' TOPG',
' PPG']
```

As colunas possuem um problema. Há um espaço antes de cada nome.

```
[8]: # Corrigindo. Tirando os espaços no nome das colunas
# Aproveitei para colocar as colunas em minúsculo
nba.columns = [c.strip().lower() for c in nba.columns]
[col for col in nba.columns.array]
```

```
[8]: ['team',
      'name',
      'experience',
      'url',
      'position',
      'age',
      'ht',
      'wt',
      'college',
      'salary',
      'ppg_last_season',
      'apg_last_season',
      'rpg_last_season',
      'per_last_season',
      'ppg_career',
      'apg_career',
      'rgp_career',
      'gp',
      'mpg',
      'fgm_fga',
      'fgp',
      'thm_tha',
      'thp',
      'ftm_fta',
      'ftp',
      'apg',
      'blkpg',
      'stlpg',
      'topg',
      'ppg']
```

2.1 Correções nas colunas

```
[9]: def is teams ok():
         # Há 30 times na NBA
         assert len(nba['team'].value counts().index) == 30
     def is_position_ok():
         pos_len = len(nba['position'].value_counts().index)
         # Geralmente se usa no basquete 5 posições.
         # Mas pode ter até 7 se considerarmos as posições G e F
         # G é um armador, mas não considerado um PG ou SG
         # F é um ala, mas não considerado um SF ou PF
         assert pos_len >= 5 and pos_len <= 7</pre>
     # Remover jogadores que não tiveram salário e nem jogaram uma partida
     def remove_players_no_games_salary(df):
         idxs = df[(df['gp'] == 0) & (df['salary'] == 0)].index
         df.drop(idxs, axis=0, inplace=True)
     # Se tiver erro vai parar o algoritmo
     # Precisa de uma intervenção manual
     is_teams_ok()
     # Se tiver erro vai parar o algoritmo
     # Precisa de uma intervenção manual
     is_position_ok()
     # "age" -> tem um bug do -
     # Vamos trocar - por O
     nba['age'] = nba['age'].str.replace('-', '0').astype(int)
     # "college" -> quem tiver "-" é porque pode ser estrangeiro,
     # veio direto do ensino médio (LeBron James), não chegou a cursar faculdade
     # ou por falta informação na coleta
     nba['college'] = nba['college'].str.replace('-', 'ND')
     # Temos 2 problemas:
     # 1) Not Signed não é um float
     # 2) Salário com ","
     nba['salary'] = nba['salary'].str.replace('Not signed', '0')
     nba['salary'] = nba['salary'].str.replace(',', '').astype(float)
     nba['salary'] = nba['salary'] / 1000000 # Colocar em milhões
     print(f'Quantidade de jogadores antes da limpeza: {nba.shape[0]}')
     remove_players_no_games_salary(nba)
```

```
# Vamos filtrar os jogadores das posições G e F. Pois são poucos
nba = nba.loc[(nba['position'] != 'G') & (nba['position'] != 'F')]
nba_bkp = nba.copy()
print(f'Quantidade de jogadores depois da limpeza: {nba.shape[0]}')
```

Quantidade de jogadores antes da limpeza: 550 Quantidade de jogadores depois da limpeza: 473

```
[10]: nba.hist(bins=50, figsize=(20,15))
```

```
[10]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x1185e7050>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x111bd3590>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a65ba50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a694dd0>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x11a6caa90>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x11a709e10>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a73ead0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a77c310>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a77ce50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a7bb810>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x11a825b50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a863ed0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a89ab50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a8d8ed0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a90db90>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x11a94df10>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a981bd0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a9c1f50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11a9f4c10>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x11aa35f90>],
             [<matplotlib.axes. subplots.AxesSubplot object at 0x11aa69c50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11aaa8fd0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11aaddc90>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11ab1c4d0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11ab51cd0>]],
            dtype=object)
```



Podemos notar que há um grupo considerável de jogadores com 0 de média em vários atributos.

3 Criar um conjunto de teste

Esse conjuto vai ser separado e não seria mexido. Vamos separar os jogadores em grupos de acordo com a sua quantidade de temporadas na liga.

Separamos em 4 categorias:


0 a 5 anos de exp

6a 10anos de exp

11 a 15 anos de exp

16 ou mais anos de exp

[11]: <matplotlib.axes._subplots.AxesSubplot at 0x1185e7790>



Agora que temos uma separação por grupo, vamos fazer o split dos conjuntos levando.

4 Visualizar e ganhar insights

4.1 Visualizar gráficos

```
[12]: def top_college_chart(df, total=15):
    order = df['college'].value_counts(ascending=False).iloc[:total].index.
    →tolist()
    fig, _ = plt.subplots(figsize=((10, 5)))

    g = sns.countplot('college', data=df, order=order)
    g.set_xlabel('Universidade')
    g.set_ylabel('Quantidade')

    for p in g.patches:
        points = p.get_bbox().get_points()
        x = sum(points[:, 0]) / 2
        y = points[1,1]
        label = '{:.1f}%'.format((y / len(df)) * 100)

        g.annotate(label, (x, y), ha='center', va='bottom')
```

```
g.set_title(f'Top {total} Universidades')
          fig.autofmt_xdate(rotation=45)
[13]: def exp_pie_chart(df):
          labels = [c + ' anos' for c in df['exp_cat'].cat.categories.tolist()]
          values = df['exp_cat'].value_counts().tolist()
          explode = (0, 0, 0.1, 0.2)
          fig, ax = plt.subplots(figsize=(5, 5))
          _,_, autotexts = ax.pie(values, labels=labels,
                 autopct='%1.1f%%', startangle=90,
                  explode=explode,
                 labeldistance=1.05, pctdistance=.55)
          ax.axis('equal')
          plt.title('Divisão por Quantidade de Temporadas')
          for autotext in autotexts:
              autotext.set_color('white')
[14]: def pos_pie_chart(df):
          counts = df['position'].value_counts()
          labels = counts.keys().tolist()
          values = counts.tolist()
          fig, ax = plt.subplots(figsize=(6, 6))
          _,_,autotexts = ax.pie(values, labels=labels,
                 autopct='%1.1f%%', startangle=0,
                 labeldistance=1.05, pctdistance=.75)
          plt.title('Divisão por Posição')
          for autotext in autotexts:
              autotext.set_color('white')
[15]: def salary_sum_chart(df):
          team_salary = df.groupby('team')['salary'].sum().
       →sort_values(ascending=False)
          labels = team_salary.index.tolist()
          values = team_salary.values
          salary_mean = np.mean(values)
          colors = ['#4C9900' if v > salary_mean else '#CC0000' for v in values]
          fig, _ = plt.subplots(figsize=(20, 8))
          ax = sns.barplot(x=labels, y=values, palette=colors)
```

```
ax.set_title('Salário Total por Time', size=20)
         ax.set_xlabel('Time', size=14)
         ax.set_ylabel('Salário (Milhões)', size=14)
         ax.axhline(salary_mean, color='blue', linewidth=.8, label='Média de Saláriou
       →por Ano')
         ax.legend()
         for p in ax.patches:
             points = p.get_bbox().get_points()
             x = sum(points[:, 0]) / 2
             y = points[1, 1]
             label = '${:.1f} M'.format(y)
             ax.annotate(label, (x, y), ha='center', va='bottom')
         fig.autofmt_xdate(rotation=45)
[16]: def stats grouped by position chart(df, attr, attr name, kind, kind name):
         g = sns.relplot(attr, y=kind,
                     col='position', col_wrap=3,
                     hue='exp_cat', size='exp_cat',
                      legend='full',
                      data=df)
         plt.subplots_adjust(top=0.90)
         g.fig.suptitle(f'Média de {attr_name} por {kind_name} - Agrupado por_
       →Posição', size=22)
         g.set_axis_labels(attr_name, kind_name)
[17]: def hightest_salary_per_position_by_team_heatmap(df):
          # ids dos jogadores com maior salario por posição por time
         nba_hghst_salary = df.groupby(['team', 'position'])['salary'].idxmax().
      →tolist()
         data = df.loc[nba_hghst_salary]
         nba_salary_table = pd.pivot_table(data, values='salary', index='team',__
      fig, ax = plt.subplots(figsize=(12, 12))
         ax.set_title('Maior Salário por Posição por Time (Milhão)')
          sns.heatmap(nba_salary_table, cmap="seismic", linewidth=.7,
                     robust=True, annot=True, annot_kws={'size': 13})
         ax.set_xlabel('Posição')
         ax.set_ylabel('Time')
```

Vamos visualizar:

Média de pontos e minutos por jogo

Média de assistências e minutos por jogo

Média de tocos e minutos por jogo

Média de roubadas e minutos por jogo

Média de turnover e minutos por jogo


Média de lance-livre e minutos por jogo

Média de field-goal e minutos por jogo

```
label = labels[idx]

ax.set_xlabel('Minutos por Jogo')
ax.set_ylabel(label)

ax.scatter(nba['mpg'], nba[key], alpha=0.3)
```




```
for idx, ax in enumerate(axs):
    key = keys[idx]
    label = labels[idx]

    ax.set_xlabel('Minutos por Jogo')
    ax.set_ylabel(label)

    ax.scatter(nba['mpg'], nba[key], alpha=0.3)

fig.tight_layout(pad=3.0)
```



```
[22]: # Analise de peso em relação aos stats
keys = ['ppg', 'apg', 'blkpg', 'stlpg', 'topg', 'ftp', 'fgp']
labels = [
    'Pontos por Jogo',
    'Assistências por Jogo',
    'Tocos por Jogo',
    'Roubadas por Jogo',
    'Roubadas por Jogo',
    'Lance Livre por Jogo (%)',
    'Field-Goal por Jogo (%)',
```


```
fig, axs = plt.subplots(6, figsize=(20,15))

for idx, ax in enumerate(axs):
    key = keys[idx]
    label = labels[idx]

    ax.set_xlabel('Peso (kg)')
    ax.set_ylabel(label)

    ax.scatter(nba['wt'], nba[key], alpha=0.3)

fig.tight_layout(pad=3.0)
```



```
'Roubadas por Jogo',
'Roubadas por Jogo',
'Lance Livre por Jogo (%)',
'Field-Goal por Jogo (%)',


fig, axs = plt.subplots(6, figsize=(20,15))

for idx, ax in enumerate(axs):
    key = keys[idx]
    label = labels[idx]


    ax.set_xlabel('Altura (cm)')
    ax.set_ylabel(label)

    ax.scatter(nba['ht'], nba[key], alpha=0.3)

fig.tight_layout(pad=3.0)
```



```
[24]: top_college_chart(nba)
```




[25]: exp_pie_chart(nba)




[26]: pos_pie_chart(nba)

Divisão por Posição



[27]: salary_sum_chart(nba)




```
[28]: kinds = ['mpg', 'salary']
kinds_name = ['Minuto', 'Salário']


attrs = ['ppg', 'apg', 'blkpg', 'stlpg', 'topg']
attrs_name = ['Pontos', 'Assistências', 'Tocos', 'Roubadas', 'Turnovers']

for kind, kName in zip(kinds, kinds_name):
    for attr, aName in zip(attrs, attrs_name):
        stats_grouped_by_position_chart(nba, attr, aName, kind, kName)
```







Média de Assistências por Minuto - Agrupado por Posição




Média de Tocos por Minuto - Agrupado por Posição



Média de Roubadas por Minuto - Agrupado por Posição




Média de Turnovers por Minuto - Agrupado por Posição




Média de Pontos por Salário - Agrupado por Posição




Média de Assistências por Salário - Agrupado por Posição




Média de Tocos por Salário - Agrupado por Posição




Média de Roubadas por Salário - Agrupado por Posição








[29]: hightest_salary_per_position_by_team_heatmap(nba)



[30]: mean_salary_per_position_by_team_heatmap(nba)



[31]: top20_salaries(nba)										
[31]:		team	name	salary	position	age	mpg	\		
	103	Golden State Warriors	Stephen Curry	37.457154	PG	30	34.4			
	510	Oklahoma City Thunder	Russell Westbrook	35.654150	PG	29	34.4			
	147	Los Angeles Lakers	LeBron James	35.654150	SF	33	38.8			
	310	Houston Rockets	Chris Paul	35.654150	PG	33	35.3			
	306	Houston Rockets	James Harden	35.650150	PG	29	33.8			
	230	Detroit Pistons	Blake Griffin	32.088932	PF	29	35.0			
	6	Boston Celtics	Gordon Hayward	31.214295	SF	28	31.3			
	89	Toronto Raptors	Kyle Lowry	31.200000	PG	32	31.1			
	502	Oklahoma City Thunder	Paul George	30.560700	SF	28	33.4			
	320	Memphis Grizzlies	Mike Conley	30.521115	PG	31	32.5			
	105	Golden State Warriors	Kevin Durant	30.000000	SF	30	37.1			
	467	Denver Nuggets	Paul Millsap	29.230769	PF	33	29.5			
	7	Boston Celtics	Al Horford	28.928709	PF	32	33.2			

```
518 Portland Trail Blazers
                                Damian Lillard
                                                27.977689
                                                                 PG
                                                                      28
                                                                          36.4
357
                                                 27.739975
                                                                          34.1
          San Antonio Spurs
                                 DeMar DeRozan
                                                                 SG
                                                                      29
452
         Washington Wizards
                               Otto Porter Jr.
                                                 26.011913
                                                                 SF
                                                                      25
                                                                          26.4
341
       New Orleans Pelicans
                                                                          32.8
                                  Jrue Holiday
                                                25.976111
                                                                 PG
                                                                      28
519
    Portland Trail Blazers
                                   CJ McCollum
                                                25.759766
                                                                 SG
                                                                      27
                                                                          29.2
         Philadelphia 76ers
                                   Joel Embiid 25.467250
                                                                  С
                                                                          28.7
67
                                                                      24
493
    Minnesota Timberwolves
                                Andrew Wiggins
                                                25.467250
                                                                 PG
                                                                      23
                                                                          36.2
               stlpg
     ppg
          apg
                       topg
103
    23.1
           6.8
                  1.8
                        3.2
510
    23.0
          8.2
                  1.7
                        4.0
147
    27.2 7.2
                  1.6
                        3.5
310
    18.7
          9.8
                  2.3
                        2.4
    23.0
306
          6.1
                  1.5
                        3.5
230 21.5 4.3
                  0.9
                        2.5
6
     15.6 3.4
                  1.0
                        2.0
89
     14.4 5.9
                  1.3
                        2.2
502 18.6
          3.2
                  1.7
                        2.6
320
    14.3 5.7
                  1.5
                        2.0
    27.1
105
          3.9
                  1.2
                        3.1
467
    14.2 2.3
                  1.3
                        1.8
     14.2 3.2
7
                  0.8
                        1.6
518 23.1 6.2
                  0.9
                        2.8
357
    19.7
          3.1
                  1.0
                        2.0
452 10.5 1.4
                  1.1
                        0.7
341
    14.9 6.2
                  1.5
                        2.7
    17.2 2.9
519
                  0.9
                        1.8
67
     22.0 2.8
                  0.7
                        3.7
```

4.2 Analisar correlação

1.0

2.1

19.7 2.1

493


Vamos analisar os valores de cada feature. Se em alguma feature possui valores estranhos.

```
[32]: corr_matrix = nba.corr()
corr_matrix['salary'].sort_values(ascending=False)
```

```
[32]: salary
                          1.000000
      ppg_last_season
                          0.671378
                          0.657985
      ppg
      ppg_career
                          0.657985
      mpg
                          0.607698
                          0.575782
      topg
      stlpg
                          0.552072
      apg_last_season
                          0.539316
                          0.527409
      gp
```

```
0.519632
apg_career
experience
                   0.486838
apg
                   0.481251
                   0.378015
blkpg
rgp_career
                   0.372038
rpg_last_season
                   0.368273
age
                   0.357326
per_last_season
                   0.351810
                   0.290302
ftp
fgp
                   0.264267
thp
                   0.237894
wt
                   0.158201
ht
                   0.070537
Name: salary, dtype: float64
```


[33]: <matplotlib.axes._subplots.AxesSubplot at 0x122c02cd0>



```
[34]: from pandas.plotting import scatter_matrix

attrs = ['salary', 'ppg', 'mpg', 'topg', 'stlpg']
scatter_matrix(nba[attrs], figsize=(12, 8))
```

```
[34]: array([[<matplotlib.axes._subplots.AxesSubplot object at 0x1184cf950>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x118366bd0>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x11d262550>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x118075910>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x11d195350>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x11d1d2a50>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x11805b410>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11812f990>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11de67250>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x1054ad410>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x1200ae250>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x121145690>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x122bd0a10>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11c7191d0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11c680a50>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x118088dd0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x122c2da90>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x1181e2b50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x11de4fad0>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x1225bce50>],
             [<matplotlib.axes._subplots.AxesSubplot object at 0x122194b10>,
              <matplotlib.axes. subplots.AxesSubplot object at 0x11e06be90>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x118018b50>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x118040ed0>,
              <matplotlib.axes._subplots.AxesSubplot object at 0x1221ddb90>]],
            dtype=object)
```



[35]: nba.plot(kind='scatter', x='ppg', y='salary', alpha=0.1)

'c' argument looks like a single numeric RGB or RGBA sequence, which should be avoided as value-mapping will have precedence in case its length matches with 'x' & 'y'. Please use a 2-D array with a single row if you really want to specify the same RGB or RGBA value for all points.

[35]: <matplotlib.axes._subplots.AxesSubplot at 0x11deb6190>



5 Preparar dados para o algoritmo de ML

Tamanho do conjunto de treino: 323

```
Tamanho do conjunto de teste: 83
     0-5
             0.626506
     6-10
              0.265060
     11-15
             0.084337
     16+
             0.024096
     Name: exp_cat, dtype: float64
     Vamos separar os conjuntos de treino e testes em strats
     5.1 Limpar dados
[37]: # Vamos pegar os dados novamente sem nenhuma alteração
     nba = strat_train_set.drop('salary', axis=1)
     nba labels = strat train set['salary'].copy()
      # Separar em dataframes com categorias númericas e categóricas
      # Removendo colunas não numéricas
      # Queremos somente as colunas numéricas
     nba_num = nba.drop(['team', 'name', 'url', 'position', 'college', 'fgm_fga', _
      # colunas categóricas que serão usadas
     nba_cat = nba[['team', 'position']]
[38]: from sklearn.impute import SimpleImputer
      # Vai adicionar O nos campos que vazios
     fill_imputer = SimpleImputer(strategy='constant', fill_value=0)
      # Vai substituir o valor zero pela mediana
     median_imputer = SimpleImputer(strategy='median', missing_values=0)
     X = fill_imputer.fit_transform(nba_num)
     X = median_imputer.fit_transform(X)
     nba_tr = pd.DataFrame(X, columns=nba_num.columns, index=nba_num.index)
     nba tr.head(5)
                                      wt ppg_last_season apg_last_season \
        experience
                              ht
                     age
               6.0 31.0 208.28 117.65
                                                      6.0
                                                                       1.1
     0
```

```
[38]:
                                                                    3.0
     4
               1.0 21.0 198.12 92.76
                                                    1.0
     5
               2.0 24.0 195.58 102.26
                                                   1.4
                                                                    0.2
               8.0 28.0
                         203.20 101.81
                                                   2.0
                                                                    3.0
              11.0 32.0 208.28 110.86
                                                   12.9
                                                                    7.4
        rpg_last_season per_last_season ppg_career apg_career rgp_career \
     0
                   5.4
                                 12.09
                                               5.4
                                                          0.7
                                                                     4.4
```

```
4
              0.5
                            -4.82
                                          1.0
                                                      3.0
                                                                 0.5
5
              0.4
                             6.88
                                          1.6
                                                      0.2
                                                                 0.5
6
              1.0
                             7.43
                                         15.6
                                                      3.4
                                                                 4.2
7
                                         14.2
                                                                 1.2
              1.1
                            17.63
                                                      8.6
                 fgp
                        thp
                              ftp apg blkpg stlpg topg
          mpg
                                                            ppg
     gp
  376.0
        15.0 0.502 0.143 0.802 0.7
                                                 0.2
                                                            5.4
0
                                          0.5
                                                       0.8
                                                            1.0
4
    2.0
          1.5 0.500 0.342 0.756 1.4
                                          0.3
                                                 0.7
                                                      0.5
   47.0
          5.8 0.418 0.294 0.710 0.2
                                          0.3
                                                      0.1
                                                            1.6
5
                                                 0.1
6 517.0 31.3 0.444 0.368 0.820 3.4
                                          0.4
                                                 1.0
                                                      2.0 15.6
7 718.0 33.2 0.525 0.370 0.750 3.2
                                          1.2
                                                 0.8
                                                      1.6 14.2
```

5.2 Cuidando dos campos de texto/categorias

```
[39]: # vamos converter categorias de texto para números
from sklearn.preprocessing import OneHotEncoder

cat_encoder = OneHotEncoder()
nba_cat_encoded = cat_encoder.fit_transform(nba_cat)
```

```
[40]: cat_encoder.categories_
```

Vamos criar um pipeline para facilitar os passos necessários que precisam ser executados

```
])
      cat_pipeline = Pipeline([
          ('cat_encoder', OneHotEncoder())
      ])
      full_pipeline = ColumnTransformer([
          ('num_pipeline', num_pipeline, num_attrs),
          ('cat_pipeline', cat_pipeline, cat_attrs)
      ])
      nba_prepared = full_pipeline.fit_transform(nba)
[42]: from sklearn.metrics import mean_squared_error
      data_test = nba.iloc[:5]
      data test labels = nba labels[:5]
      data_test_prepared = full_pipeline.transform(data_test)
[43]: # EXEMPLO DE UNDERFITTING?
      from sklearn.linear_model import LinearRegression
      lin_reg = LinearRegression()
      lin_reg.fit(nba_prepared, nba_labels)
      nba_predictions = lin_reg.predict(data_test_prepared)
      print(f'Predictions: {nba_predictions}')
      print(f'Labels: {list(data test labels)}')
      lin_mse = mean_squared_error(data_test_labels, nba_predictions)
      lin_rsme = np.sqrt(lin_mse)
      print(f'RSME: {lin_rsme}')
     Predictions: [ 4.56359863  0.28820801 -0.18530273 14.26464844 18.78198242]
     Labels: [5.1936, 0.0, 0.0, 31.214295, 28.928709]
     RSME: 8.84037195514633
[44]: # EXEMPLO DE OVERFITTING?
      from sklearn.tree import DecisionTreeRegressor
      tree_reg = DecisionTreeRegressor()
      tree_reg.fit(nba_prepared, nba_labels)
      nba_predictions_2 = tree_reg.predict(data_test_prepared)
```

```
print(f'Predictions: {nba_predictions_2}')
print(f'Labels: {list(data_test_labels)}')

tree_mse = mean_squared_error(data_test_labels, nba_predictions_2)
tree_rsme = np.sqrt(tree_mse)
print(f'RSME: {tree_rsme}')
```

```
[45]: from sklearn.ensemble import RandomForestRegressor

forest_reg = RandomForestRegressor()
  forest_reg.fit(nba_prepared, nba_labels)

nba_predictions_3 = forest_reg.predict(data_test_prepared)

print(f'Predictions: {nba_predictions_3}')
  print(f'Labels: {list(data_test_labels)}')

forest_mse = mean_squared_error(data_test_labels, nba_predictions_3)
  forest_rmse = np.sqrt(forest_mse)

print(f'RSME: {forest_rmse}')
```

5.3 Usando cross-validation

A ideia é analisar qual o modelo apresenta melhor expectativa para ser utilizado como nosso modelo final.

```
[46]: def display_scores(scores):
    print(f'Scores: {scores}')
    print(f'Mean: {scores.mean()}')
    print(f'Standard Deviation: {scores.std()}')
```

```
[47]: from sklearn.model_selection import cross_val_score
      # Cross Validation usando a árvore de decisão
      tree_scores = cross_val_score(tree_reg,
                               nba_prepared, nba_labels,
                               scoring='neg_mean_squared_error',
      tree_rmse_scores = np.sqrt(-tree_scores)
      print('Árvore de decisão:')
      display_scores(tree_rmse_scores)
      print('-' * 70 + '\n')
      # Cross Validation usando regressão linear
      lin_reg_scores = cross_val_score(lin_reg,
                                        nba_prepared, nba_labels,
                                        scoring='neg_mean_squared_error',
                                        cv=10)
      lin_reg_rmse_scores = np.sqrt(-lin_reg_scores)
      print('Regressão linear:')
      display_scores(lin_reg_rmse_scores)
      print('-' * 70 + '\n')
      # Cross Validation usando a floresta aleatórias
      forest_scores = cross_val_score(forest_reg,
                                      nba_prepared, nba_labels,
                                      scoring='neg_mean_squared_error',
      forest_rmse_scores = np.sqrt(-forest_scores)
      print('Florestas Aleatórias:')
      display_scores(forest_rmse_scores)
      print('-' * 70 + '\n')
     Árvore de decisão:
     Scores: [3.57507994 7.27237962 5.06371998 3.49907171 7.06561995 6.52071773
      9.13963013 7.51800389 6.94867555 6.18828015]
     Mean: 6.279117865875032
     Standard Deviation: 1.6838979395011766
     Regressão linear:
     Scores: [5.56125769e+11 5.13004777e+11 1.00732539e+11 1.04232410e+12
      5.89073236e+00 1.42493961e+12 1.05446980e+12 4.14619824e+10
      7.98213196e+11 3.12927039e+12]
```

```
Mean: 866054215875.0836
```

Standard Deviation: 879891658905.8341

Florestas Aleatórias:

Scores: [5.12675887 5.0965817 3.92850941 4.32315549 5.51383977 4.60178764

7.20677244 4.45849796 5.07328264 6.52554737]

Mean: 5.185473329371152

Standard Deviation: 0.9594759727725465

5.4 Sintonia fina do modelo

5.4.1 GridSearch

/usr/local/lib/python3.7/site-packages/sklearn/model_selection/_search.py:814: DeprecationWarning: The default of the `iid` parameter will change from True to False in version 0.22 and will be removed in 0.24. This will change numeric results when test-set sizes are unequal.

DeprecationWarning)

5.5 Testando Árvores Aleatórias

5.5.1 Usando os parâmetros encontrados pelo GridSearch

```
[49]: data_test = nba.iloc[:5]
    data_test_labels = nba_labels[:5]

data_test_prepared = full_pipeline.transform(data_test)

final_model = grid_search.best_estimator_
    nba_predictions_f = final_model.predict(data_test_prepared)

print(f'Predictions: {nba_predictions_f}')
print(f'Labels: {list(data_test_labels)}')

final_model_mse = mean_squared_error(data_test_labels, nba_predictions_f)
final_model_rmse = np.sqrt(final_model_mse)

print(f'RSME: {final_model_rmse}')
```

Predictions: [6.56796383 0.13590027 0.26372877 25.20826007 26.96491707] Labels: [5.1936, 0.0, 0.0, 31.214295, 28.928709] RSME: 2.8950244236989673

5.5.2 RandomizedSearch

```
[50]: from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import randint

param_distribs = {
    'n_estimators': randint(low=1, high=200),
    'max_features': randint(low=1, high=10)
}
```

/usr/local/lib/python3.7/site-packages/sklearn/model_selection/_search.py:814: DeprecationWarning: The default of the `iid` parameter will change from True to False in version 0.22 and will be removed in 0.24. This will change numeric results when test-set sizes are unequal.

DeprecationWarning)

```
[50]: RandomizedSearchCV(cv=10, error score='raise-deprecating',
                         estimator=RandomForestRegressor(bootstrap=True,
                                                          criterion='mse',
                                                          max_depth=None,
                                                          max features='auto',
                                                          max_leaf_nodes=None,
                                                          min_impurity_decrease=0.0,
                                                          min_impurity_split=None,
                                                          min_samples_leaf=1,
                                                          min_samples_split=2,
                                                          min_weight_fraction_leaf=0.0,
                                                          n_estimators='warn',
                                                          n_jobs=None, oob_score=False,
                                                          random_st...
                                                          warm_start=False),
                         iid='warn', n_iter=15, n_jobs=None,
                         param_distributions={'max_features':
      <scipy.stats._distn_infrastructure.rv_frozen object at 0x11eb28d90>,
                                               'n_estimators':
      <scipy.stats._distn_infrastructure.rv_frozen object at 0x11eb28b90>},
                         pre_dispatch='2*n_jobs', random_state=42, refit=True,
                         return_train_score=False, scoring='neg_mean_squared_error',
                         verbose=0)
```

5.6 Testando Árvores Aleatórias

5.6.1 Usando os parâmetros encontrados pelo RandomizedSearch

```
[51]: data_test = nba.iloc[:5]
    data_test_label = nba_labels.iloc[:5]

data_test_prepared = full_pipeline.transform(data_test)
```

```
final_model = rnd_search.best_estimator_
      final_model.fit(nba_prepared, nba_labels)
      nba_predcitions_f_2 = final_model.predict(data_test_prepared)
      print(f'Predictions: {nba_predcitions_f_2}')
      print(f'Labels: {list(data_test_labels)}')
      final_model_mse = mean_squared_error(data_test_labels, nba_predcitions_f_2)
      final_model_rmse = np.sqrt(final_model_mse)
      print(f'RSME: {final_model_rmse}')
     Predictions: [ 5.61378296  0.32067446  0.44243049  24.51912922  25.06424902]
     Labels: [5.1936, 0.0, 0.0, 31.214295, 28.928709]
     RSME: 3.4708623235413416
[52]: # Importância das funcionalidades
      features_importances = grid_search.best_estimator_.feature_importances_
      cat_encoder = full_pipeline.named_transformers_['cat_pipeline'].

¬named_steps['cat_encoder']
      cat_encoder_categories = cat_encoder.categories_
      cat_enconder_attrs = list(cat_encoder_categories[0]) +__
      →list(cat_encoder_categories[1])
      attrs = list(num_attrs) + cat_enconder_attrs
      for importance, attr in sorted(zip(features_importances, attrs), reverse=True):
          print(f'{attr} - {importance * 100: .2f}%')
     ppg_last_season - 12.36%
     ppg - 11.07%
     ppg_career - 7.98%
     experience - 7.07%
     gp - 6.40%
     per_last_season - 5.42%
     mpg - 5.15%
     topg - 4.70%
     apg - 4.30%
     age - 4.07%
     stlpg - 4.01%
     apg_career - 3.90%
     apg_last_season - 3.52%
     rpg_last_season - 2.50%
     fgp - 2.30%
     blkpg - 2.27%
```

```
thp - 2.10%
wt - 1.79%
ftp - 1.73%
rgp_career - 1.68%
ht - 1.58%
PG - 0.39%
Washington Wizards - 0.37%
Memphis Grizzlies - 0.35%
Chicago Bulls - 0.33%
Houston Rockets - 0.27%
SF - 0.24%
Phoenix Suns - 0.20%
SG - 0.19%
PF - 0.18%
C - 0.17\%
Detroit Pistons - 0.16%
Indiana Pacers - 0.14%
Boston Celtics - 0.14%
Toronto Raptors - 0.13%
Orlando Magic - 0.11%
Miami Heat - 0.08%
Charlotte Hornets - 0.06%
New Orleans Pelicans - 0.06%
Philadelphia 76ers - 0.06%
LA Clippers - 0.05%
New York Knicks - 0.05%
Milwaukee Bucks - 0.05%
Cleveland Cavaliers - 0.05%
Brooklyn Nets - 0.05%
Dallas Mavericks - 0.05%
Denver Nuggets - 0.04%
Atlanta Hawks - 0.04%
San Antonio Spurs - 0.04%
Sacramento Kings - 0.02%
Los Angeles Lakers - 0.02%
Golden State Warriors - 0.01%
```

Podemos notar que a posição do jogador e/ou o time que ele joga tem muita pouca importância para determinar seu salário.

Como a resposta para o trabalho é se o salário da temporada é justo, eu não vou considerar as estatísticas da temporada passada e nem sua média durante a carreira.

Depois será feito um teste sem os jogadores que receberam algum salário, mas não fizeram nenhum ponto, assistência e etc. Pode ser um jogador que recebeu o salário, se machucou e ficou fora da temporada, como pode ser dados inexatos.

```
[53]: from sklearn.pipeline import Pipeline from sklearn.preprocessing import StandardScaler
```

5.6.2 RandomizedSearch

/usr/local/lib/python3.7/site-packages/sklearn/model_selection/_search.py:814: DeprecationWarning: The default of the `iid` parameter will change from True to False in version 0.22 and will be removed in 0.24. This will change numeric results when test-set sizes are unequal.

DeprecationWarning)

```
[54]: RandomizedSearchCV(cv=10, error_score='raise-deprecating',
                         estimator=RandomForestRegressor(bootstrap=True,
                                                          criterion='mse',
                                                          max_depth=None,
                                                          max features='auto',
                                                          max_leaf_nodes=None,
                                                          min impurity decrease=0.0,
                                                          min_impurity_split=None,
                                                          min_samples_leaf=1,
                                                          min_samples_split=2,
                                                          min_weight_fraction_leaf=0.0,
                                                          n_estimators='warn',
                                                          n_jobs=None, oob_score=False,
                                                          random st...
                                                          warm_start=False),
                         iid='warn', n_iter=15, n_jobs=None,
                         param_distributions={'max_features':
      <scipy.stats._distn_infrastructure.rv_frozen object at 0x11eb3ed50>,
                                               'n_estimators':
      <scipy.stats._distn_infrastructure.rv_frozen object at 0x11eb09f90>},
                         pre_dispatch='2*n_jobs', random_state=42, refit=True,
                         return_train_score=False, scoring='neg_mean_squared_error',
                         verbose=0)
```

5.7 Testando Árvores Aleatórias

5.7.1 Utilzando o melhor modelo encontrado pelo RandomizedSearch

```
[55]: def test_data_test():
    print(f'NBA Shape: {nba.shape}')
    full_pipeline = get_num_column_pipeline()
    nba_prepared = full_pipeline.fit_transform(nba)

    data_test = nba.iloc[:5]
    data_test_labels = nba_labels.iloc[:5]

    data_test_prepared = full_pipeline.transform(data_test)

    final_model = rnd_search.best_estimator_
    final_model.fit(nba_prepared, nba_labels)

    nba_predictions = final_model.predict(data_test_prepared)

    print(f'Predictions: {nba_predictions}')
    print(f'Labels: {list(data_test_labels)}')

    final_model_mse = mean_squared_error(data_test_labels, nba_predictions)
```

```
final_model_rmse = np.sqrt(final_model_mse)

print(f'RSME: {final_model_rmse}')

# Testando antes de remover os jogadores que não contribuíram
test_data_test()
```

NBA Shape: (323, 29)

Predictions: [6.22226754 0.51693788 0.36693528 27.49760038 24.0461203]

Labels: [5.1936, 0.0, 0.0, 31.214295, 28.928709]

RSME: 2.7969095273838445

Melhorou o nosso erro, mas ainda vamos testar removendo os jogadores que não tiveram nenhum estatística durante o ano (gp/ppg/apg).

NBA Shape: (291, 29)

Predictions: [5.64223255 0.47153481 0.48183596 26.36100652 25.9946519]

Labels: [5.1936, 0.0, 0.0, 31.214295, 28.928709]

RSME: 2.5619868185085934

Remover 79 jogadores que não possui estatísticas não melhorou tanto o nosso modelo. Tem momentos que o erro é menor e outras que são maiores.

5.8 Teste final

Vamos utilizar o conjunto de teste para avaliar

```
[57]: final_model = rnd_search.best_estimator_

# Um jogador estrela

curry_idx = nba_bkp[nba_bkp['name'] == 'Stephen Curry'].index

curry = nba_bkp.loc[curry_idx]

curry_feature = curry.drop('salary', axis=1)
```

```
curry_label = curry['salary'].copy().iloc[0]
# Um jogador sem ser estrela
abaynes = nba_bkp.loc[[0]]
abaynes_feature = abaynes.drop('salary', axis=1)
abaynes_label = abaynes['salary'].copy().iloc[0]
X_test = strat_test_set.drop('salary', axis=1)
y test = strat test set['salary'].copy()
pipeline = get_num_column_pipeline()
pipeline.fit(nba)
X_test_prepared = pipeline.transform(X_test)
predicted = final_model.predict(X_test_prepared)
final_model_mse = mean_squared_error(y_test, predicted)
final_model_rmse = np.sqrt(final_model_mse)
print(f'RMSE do modelo final: {final_model_rmse: .2f}M\n')
pipeline.fit(nba)
tst_features_prepared = pipeline.transform(pd.concat([curry_feature,_
→abaynes feature]))
tst_predicted = final_model.predict(tst_features_prepared)
curry_predicted = tst_predicted[0]
abaynes_predicted = tst_predicted[1]
print(f'Salário do Stephen Curry deveria ser: {curry_predicted:.1f}M\n')
print(f'Salário do Stephen Curry é: {curry_label:.1f}M\n')
print(f'Diferença: {curry_label - curry_predicted: .1f}M\n')
print(f'Erro de {(100 - (curry_predicted * 100) / curry_label): .1f}%')
print('')
print('*' * 40)
print('')
print(f'Salário do Aron Baynes deveria ser: {abaynes_predicted:.1f}M\n')
print(f'Salário do Aron Baynes é: {abaynes_label:.1f}M\n')
print(f'Diferença: {abaynes_label - abaynes_predicted: .1f}M\n')
print(f'Erro de {(100 - (abaynes_predicted * 100) / abaynes_label): .1f}%')
```

RMSE do modelo final: 5.67M

Salário do Stephen Curry deveria ser: 33.1M

Salário do Stephen Curry é: 37.5M

Diferença: 4.3M

Erro de 11.5%

Salário do Aron Baynes deveria ser: 5.6M

Salário do Aron Baynes é: 5.2M

Diferença: -0.4M

Erro de -8.6%

6 Conclusão

É sabido que vários fatores externos determinam o salário de um jogador, principalmente se ele for uma estrela. Um jogador de grande repercussão traz patrocinadores, mais telespectadores, maior público, vende mais camisas e entre outros...

Isso pode fazer com que um algoritmo de aprendizado de máquina, que só analisa seu desempenho em quadra não consiga prever se seu salário é compatível ou não.

O algoritmo utilizado nesse trabalho chegou bem perto do salário recebido pelo Stephen Curry. Eu diria que seu salário é justo, levando em consideração apenas suas estatística dentro de quadra.